

Adversarial Attacks

September 1, 2026

1 실험 환경

- MNIST용 CNN (테스트 정확도 99.01%)과 CIFAR-10용 fine-tuned ResNet18 (테스트 정확도 85.67%)을 학습하였다.
- 구현 과정에서 입력 이미지에 정규화(normalization)를 적용하면 픽셀값이 $[0, 1]$ 범위를 벗어나 `clamp(0, 1)` 연산이 perturbation을 과도하게 잘라내는 문제가 발생하였다.
- 이를 해결하기 위해 정규화를 제거하고 픽셀값을 $[0, 1]$ 로 유지하였다.

2 공격 성공률 결과

표 1은 $\epsilon \in \{0.05, 0.1, 0.2, 0.3\}$ 에 대한 각 공격 방법의 성공률(100개 샘플 기준)을 나타낸다.

Table 1: ϵ 별 공격 성공률 (%). T=Targeted, U=Untargeted

ϵ	MNIST				CIFAR-10			
	FGSM-T	FGSM-U	PGD-T	PGD-U	FGSM-T	FGSM-U	PGD-T	PGD-U
0.05	0.0	4.0	0.0	6.0	44.0	98.0	100.0	100.0
0.1	0.0	11.0	3.0	28.0	28.0	94.0	100.0	100.0
0.2	14.0	49.0	88.0	100.0	14.0	84.0	100.0	100.0
0.3	39.0	74.0	100.0	100.0	14.0	85.0	100.0	100.0

- **PGD vs. FGSM.** PGD는 $k = 40$ 번 반복하며 ϵ -ball 내에서 loss를 최대화하는 점을 탐색하므로, 단일 step의 FGSM보다 일관되게 강력하다. 특히 MNIST PGD의 경우 $\epsilon = 0.3$ 에서 targeted/untargeted 모두 100%를 달성한 반면, FGSM은 각각 39%, 74%에 그쳤다.
- **Targeted vs. Untargeted.** Targeted 공격은 특정 클래스로의 유도가 필요하므로 untargeted 대비 성공률이 낮다. MNIST FGSM의 경우 $\epsilon = 0.1$ 에서 targeted 0%, untargeted 11%로 뚜렷한 차이를 보였다.
- **ϵ 과 visibility의 trade-off.** ϵ 이 클수록 공격 성공률은 전반적으로 높아지지만, 그림 3에서 확인할 수 있듯 perturbation이 육안으로 식별 가능해진다. 실제 공격 시나리오에서는 imperceptibility를 유지하면서 성공률을 높이는 ϵ 선택이 중요하다.
- **CIFAR-10 FGSM Targeted.** 표 1에서 CIFAR-10 FGSM-T는 ϵ 이 증가할수록 성공률이 오히려 감소하는 역설적 패턴을 보였다 (44% $\rightarrow$ 28% $\rightarrow$ 14% $\rightarrow$ 14%). 그림 4를 보면 ϵ 이 커질수록 adversarial 이미지가 원본과 전혀 다른 형태로 왜곡되는데, 이는 단일 gradient step이 loss landscape에서 target class 영역을 overshooting하여 의도치 않은 다른 클래스로 수렴했기 때문으로 해석된다. 이는 고차원 공간에서 1-step 공격의 한계를 잘 보여준다.

3 시각화




Figure 1: MNIST FGSM Targeted ($\epsilon = 0.1$): 공격 실패 — perturbation이 존재하지만 모델은 여전히 정답(2)으로 분류.




Figure 2: MNIST PGD Targeted ($\epsilon = 0.3$): 공격 성공 — 2를 3으로 오분류. FGSM 대비 perturbation이 더 구조적으로 분포.




Figure 3: CIFAR-10 PGD Untargeted ($\epsilon = 0.3$): 공격 성공 — 선박(8)을 비행기(0)로 오분류. perturbation이 육안으로 확인될 정도로 큼.




Figure 4: CIFAR-10 FGSM Targeted: ϵ 별 비교. $\epsilon = 0.05$ 에서 성공(3→4)했으나 ϵ 이 커질수록 오히려 실패(3→2, 3→6). perturbation은 커졌지만 성공률은 감소.